

Import des données et vérification des valeurs manquantes ou nulles

| | DATE | FFR | Tbill | Tb1yr | r5 | r10 | PPINSA | Finished | CPI | CPICORE | M1NSA | M2SA | M2NSA | Unemp | IndProd | RGDP | Potent | Deflator | Curr |
|---|--------|------|-------|-------|------|------|--------|----------|-------|---------|--------|-------|--------|-------|---------|--------|--------|----------|--------|
| 0 | 1960Q1 | 3.93 | 3.87 | 4.57 | 4.64 | 4.49 | 31.67 | 33.20 | 29.40 | 18.92 | 140.53 | 896.1 | 299.40 | 5.13 | 23.93 | 2845.3 | 2824.2 | 18.521 | 31.830 |
| 1 | 1960Q2 | 3.70 | 2.99 | 3.87 | 4.30 | 4.26 | 31.73 | 33.40 | 29.57 | 19.00 | 138.40 | 903.3 | 300.03 | 5.23 | 23.41 | 2832.0 | 2851.2 | 18.579 | 31.862 |
| 2 | 1960Q3 | 2.94 | 2.36 | 3.07 | 3.67 | 3.83 | 31.63 | 33.43 | 29.59 | 19.07 | 139.60 | 919.4 | 305.50 | 5.53 | 23.02 | 2836.6 | 2878.7 | 18.648 | 32.217 |
| 3 | 1960Q4 | 2.30 | 2.31 | 2.99 | 3.75 | 3.89 | 31.70 | 33.67 | 29.78 | 19.14 | 142.67 | 932.8 | 312.30 | 6.27 | 22.47 | 2800.2 | 2906.7 | 18.700 | 32.624 |
| 4 | 1961Q1 | 2.00 | 2.35 | 2.87 | 3.64 | 3.79 | 31.80 | 33.63 | 29.84 | 19.17 | 142.23 | 948.9 | 317.10 | 6.80 | 22.13 | 2816.9 | 2934.8 | 18.743 | 32.073 |

Nous n'avons pas détecté de valeurs manquantes ou nulles dans la série.

Etude de la série de CPI

Définition du CPI: En anglais, Consumer Price Index, ou indice des prix à la consommation, est un indicateur économique, qui permet d'étudier l'évolution du prix d'un panier type de biens de consommation et de services achetés par les ménages (ex: transport, alimentation, services médicaux...). Les changements du CPI sont associés à des changements du coût de la vie. Il est également utilisé pour étudier des périodes d'inflation et de déflation. Pour en apprendre plus, voir le lien ci-dessous.


Source: <https://www.investopedia.com/terms/c/consumerpriceindex.asp>

Description et visualisation de la série.

Description Générale:

```
count    212.000000
mean     113.182028
std       65.310267
min       29.400000
25%       43.705000
50%      109.635000
75%      167.507500
max      231.280000
Name: CPI, dtype: float64
```

Graphique du CPI en fonction du temps



Nous pouvons remarquer que la série a une tendance générale croissante, ce qui est en cohérence avec le développement économique. La série est donc clairement non stationnaire.

▼ Stationnarisation de la série de CPI



Définition de quelques termes:

- La **tendance** de la série temporelle caractérise son évolution générale durant de le temps.
- La **stationnarité** d'une série temporelle est définie par une moyenne constante durant le temps, et la non accumulation des effets précédents.

- **Stationnariser une série:** Est l'action de rendre une série stationnaire, en retirant le terme de tendance. Ceci permet de contrôler les auto-corrélations de la série.

Pour stationnariser la série, plusieurs types de tendances vont être étudiés: tendance linéaire, quadrature, log, et exponentielles. Nous déterminerons par la suite la tendance la plus adéquate à la


▼ Tendance Linéaire




Le coefficient de détermination obtenu est: 0.9828376652371925

La stationnarisation est non satisfaisante. En effet, il réside une tendance décroissante au niveau des résidus entre 1960 et 1970. De plus, les résidus ne sont pas répartis aléatoirement autour de zéro.

▼ Tendence Quadratique d'ordre 2




Série de CPI stationnarisée avec une tendance quadratique d'ordre 2




Le coefficient de détermination obtenu est: 0.9904534599108377

La stationnarisation est non satisfaisante, pour les mêmes raisons que la tendance linéaire.

▼ Tendence Quadratique d'ordre 4




Série de CPI stationnarisée avec une tendance quadratique d'ordre 4



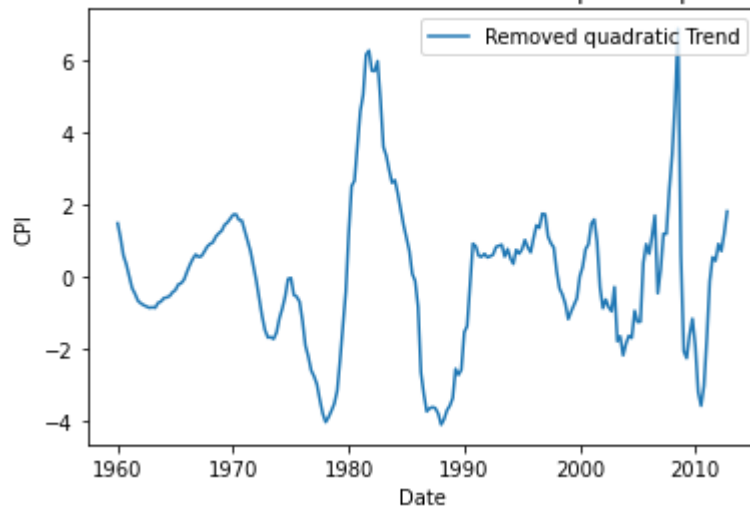
Le coefficient de détermination obtenu est: 0.9981264534424436

Les résultats sont plus satisfaisants que ceux obtenus précédemment. Cependant on remarque encore une tendance cyclique au niveau des résidus.

▼ Tendence Quadratique d'ordre 6





Série de CPI stationnarisée avec une tendance quadratique d'ordre 6



Le coefficient de détermination obtenu est: 0.9989621504553035



La composante cyclique persiste ici aussi.

▼ Stationnarisation logarithmique



La modélisation n'est pas satisfaisante, la tendance ne suit pas du tout l'évolution de la courbe.

▼ Stationnarisation exponentielle





Le coefficient de détermination obtenu est: 0.9607548822574083

Les résidus ne sont pas répartis aléatoirement autour de 0, le modèle de tendance n'est pas valide

▼ Stationnarisation avec moyenne mobile

- **Moyenne mobile:** La moyenne mobile, ou moyenne glissante, (moving average), est une moyenne statistique adaptée aux analyse de séries temporelles. La moyenne est réalisé sur les valeur précédentes et/ou suivantes du point en considération. Cette moyenne est appelée mobile car calculée pour chaque pas de temps. Pour plus d'informations, voir la source.

Source: https://fr.wikipedia.org/wiki/Moyenne_mobile



Ce modèle correspond mieux, car les résidus sont bien centrés autour de zéro. Cependant, les résidus ne sont pas stationnaire. En effet, même si la moyenne semble constante, la variance elle ne l'est pas. On remarque des période de grandes variation notamment en période de crise, commen en 2008. Ce qui est tout à fait en cohérence avec les principes économique de fluctuation du CPI.

▼ Etude de l'inflation

Inflation: L'inflation caractérise la décroissance du pouvoir d'achat d'une monnaie au cours du temps. L'inflation peut être étudiée ent utilisant la le CPI, et la formule suivante:

Entre 1960 et 1980, on remarque une forte augmentation générale du taux d'inflation. Puis une importante baisse générale entre 1980 et 1990. Pour ensuite se stabiliser jusqu'en 2008 où l'on observe une chute du taux d'inflation, et une variation importante. Ce graphique est assez parlant,

en effet on peut y voir différent événement marquant de l'histoire économique américaine, en observant les différentes régions de grandes variations.


Etude des autocorrélogrammes (ACF) et autocorrélogrammes partiels (PACF) de l'inflation




Quelques définitions:

- **Autocorrelation Function ACF:** Correspond aux corrélations de la série suivant ses propres lags. Soit k un lag de la série y , le coefficient associé au lag k correspond à $Cov(y_{t+k}, y_t)$
- **Partial Autocorrelation function PACF:** Correspond aux corrélations entre la série avec en fonction de ses lags, en prenant des intervalles intermédiaires. Dans ce cas, nous prenons en compte une régression linéaire. Pour le lag k , on considère la $Cov(y_{t+k}, y_t)$ où y_{t+k} est défini tel quel:

$$y_{t+k} = \beta_0 + \beta_1 y_{t-k+1} + \dots + \beta_k y_t + \epsilon_t$$

avec ϵ_t correspondant au résidu à l'instant t .





Les graphiques:

Dans les deux cas, l'axe **y** correspond à la **correlation entre la série et un lag donné**, et l'axe **x** correspond au lag étudié.

Le **cône bleu** présent dans les des graphiques correspond à l'**intervalle de confiance** à 95% par défaut. Si le point est en dehors du cône (dans la zone blanche), nous pouvons en conclure qu'à 5% de risque, le lag est significativement impactant sur la série, et donc corrélé au signal. Sinon, le lag est dans la zone bleu, et nous pouvons interpréter cela, comme une non significativité de ce lag particulier, et donc l'ignorer dans le cadre de la modélisation.

Liens utiles:

- <https://medium.com/@krzysztofrelczuk/acf-autocorrelation-function-simple-explanation-with-python-example-492484c32711>
- <https://machinelearningmastery.com/gentle-introduction-autocorrelation-partial-autocorrelation/>

Interprétations des graphiques:

Sur le premier graphique de l'ACF, on peut dire que les 8 premiers lags sont significatifs.

Sur le graphique du PACF nous pouvons remarquer que les 3 premiers lags sont significatifs. On peut également remarquer qu'il existe des lags impactants à environs 20 lags d'écart et 100 lags d'écart, ce qui pourrait dénoter une certaine cyclicité.

Stationnarité et Ergodicité

- **La stationnarité** d'une série temporelle en est une propriété fondamentale. Elle indique si les caractéristiques de celui-ci changent avec le temps ou non. On rappelle une série temporelle X_t est stationnaire au sens large si $E(X_t) = \mu$ (constante) $\forall t$ et $E(X_t^2) < \infty$ et ne dépend pas du temps t et $cov(X_t, X_{t-k}) = \sigma(k)$ ne dépend également pas de t . Il est crucial qu'une série temporelle soit stationnaire car c'est la garantie qu'elle présente les mêmes propriétés statistiques au cours du temps.
- **Ergodicité** en revanche, il suffit essentiellement que X_t et X_s soient asymptotiquement indépendants quand $|t - s|$ tend vers l'infini. En d'autres termes une série temporelle X_t est ergodique si $cov(X_t, X_{t-k})$ tend vers 0 quand k tend vers $+\infty$. Il est important qu'une série temporelle soit ergodique car elle permet notamment de pouvoir utiliser la loi des grands nombres et le théorème de limite centrale. Avec suffisamment d'observations on peut atteindre les propriétés théoriques du processus. L'ergodicité permet d'assurer que l'estimateur de la série temporelle est non biaisé, et que donc les paramètres le sont aussi.

- **Spurious regression** (régression fallacieuse) désigne une situation dans laquelle l'utilisation de séries temporelles non stationnaires dans une régression linéaire fait apparaître des résultats erronés, trop optimistes, qui font croire à une relation entre les variables alors que ce n'est pas le cas. Souvent les régressions fallacieuses apparaissent lorsqu'il y a une régression d'une marche aléatoire vers une autre marche aléatoire indépendante. On remarquera alors que l'estimation du coefficient ne convergera pas vers zéro (la vraie valeur). Au lieu de cela, dans la limite, l'estimation du coefficient suivra une distribution non dégénérée. La valeur de t sera le plus souvent significative, et le coefficient de détermination (R^2) élevé. On peut également les retrouver quand les séries sont non stationnaires, et contiennent des tendances stochastiques, ou des tendances similaires. Il existe cependant des moyens de relever des régressions fallacieuses. Comme par exemple la présence d'une racine unitaire au niveau des résidus. Pour cette raison, il est primordial de valider la stationnarité des résidus.

Sources intéressantes:

- http://www.fsb.miamioh.edu/lij14/672_2014_s8.pdf
- https://en.wikipedia.org/wiki/Spurious_relationship#:~:text=An%20example%20of%20a%20spurious,between%20independent%20non%2Dstationary%20variables
- <https://kidbrooke.com/risk-dictionary/stationarity-and-ergodicity/>

▼ Test de stationnarité

Explications des tests de stationnarité

Comme expliqué précédemment, la stationnarité est une propriété importante pour l'étude d'une série temporelle. Il existe plusieurs manières de vérifier la stationnarité d'une série:

- Visualisation de la série temporelle
- Séparer la série en 2, et calculer les statistiques de moyenne de variance et d'autocorrélation, et comparer les deux résultats statistiques obtenus. S'ils sont significativement différents, il sera suggéré que la série est non stationnaire.
- Utiliser les méthodes quantitatives. En utilisant par exemple les tests de racines unitaires. Parmi ces tests, nous pouvons noter:
 - Augmented Dickey Fuller test (ADF Test)
 - Kwiatkowski-Phillips-Schmidt-Shin – KPSS test (trend stationary)
 - Philips Perron test (PP Test)

Augmented Dickey Fuller est le plus communément utilisé. Dans le cadre de ce test, l'hypothèse nulle H_0 consiste à affirmer que la série temporelle possède une racine unitaire, et est non

stationnaire. Si la p-value du test ADF est inférieure au risque, l'hypothèse nulle est alors acceptée.

Plus d'informations sur: <https://www.kaggle.com/prashant111/complete-guide-on-time-series-analysis-in-python>

▼ Réalisation du test Augmented Dickey Fuller test (ADF Test)

Résultat obtenus avec les paramètres par défaut:

- ADF Statistic: -2.9190558143372347
- p-value: 0.04317651687154687
- Critical Values: 1%, -3.4621857592784546
- Critical Values: 5%, -2.875537986778846
- Critical Values: 10%, -2.574231080806213

-Nombre de lags minimisant l'AIC: 2

On a un P-value $\approx 0.04 < 0.05$, H_0 est rejeté. D'après ce test, la série temporelle qui représente l'inflation est semble stationnaire. Or la visualisation de la série semble suggérer une conclusion opposée. Je pense que cela est dû au type de régression choisie par défaut au niveau du test, qui considère seulement la constante. A mon sens il faudrait inclure la tendance également au test. Les résultats de ce test sont repertoriés ci-dessous:

- ADF Statistic: -3.1334995610190464
- p-value: 0.09848521134086352
- Critical Values: 1%, -4.002966509244673
- Critical Values: 5%, -3.43181159172131
- Critical Values: 10%, -3.139573978276485
- Nombre de lags minimisant l'AIC: 2


On a un P-value $\approx 0.09 > 0.05$, H_0 est acceptée. D'après ce test, la série temporelle qui représente l'inflation est donc non stationnaire.

▼ Modélisation AR(p) de l'inflation

Pour ce test nous allons d'abord tester plusieurs valeurs pour déterminer empiriquement le meilleur nombre de lags. Nous utiliserons également le modèle auto arima. Nous confirmerons ensuite les

résultats en utilisant les graphiques d'ACF et PACF. Nous déterminerons ensuite les coefficients du modèle.

▼ En testant plusieurs paramètres



Le meilleur nombre de lags pour minimiser l'AIC est: 3

▼ En utilisant auto arima

Best model: ARIMA(3,1,2)(0,0,0)[0]

Total fit time: 5.350 seconds

SARIMAX Results

| | | | |
|-----------------------|------------------|--------------------------|----------|
| Dep. Variable: | y | No. Observations: | 211 |
| Model: | SARIMAX(3, 1, 2) | Log Likelihood | -431.149 |
| Date: | Sun, 16 May 2021 | AIC | 874.298 |
| Time: | 23:10:21 | BIC | 894.381 |
| Sample: | 0 | HQIC | 882.417 |
| | - 211 | | |

Covariance Type: opg

| | coef | std err | z | P> z | [0.025 | 0.975] |
|---------------|---------|---------|--------|-------|--------|--------|
| ar.L1 | 0.1403 | 0.244 | 0.574 | 0.566 | -0.339 | 0.619 |
| ar.L2 | 0.1651 | 0.180 | 0.916 | 0.360 | -0.188 | 0.518 |
| ar.L3 | 0.2942 | 0.054 | 5.451 | 0.000 | 0.188 | 0.400 |
| ma.L1 | -0.5196 | 0.267 | -1.942 | 0.052 | -1.044 | 0.005 |
| ma.L2 | -0.3866 | 0.240 | -1.610 | 0.107 | -0.857 | 0.084 |
| sigma2 | 3.5431 | 0.143 | 24.821 | 0.000 | 3.263 | 3.823 |

Ljung-Box (L1) (Q): 0.00 **Jarque-Bera (JB):** 2055.37

Prob(Q): 0.96 **Prob(JB):** 0.00

Heteroskedasticity (H): 2.77 **Skew:** -2.22

Prob(H) (two-sided): 0.00 **Kurtosis:** 17.67



Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

D'après le modèle ARMA, le paramètre p minimisant au mieux l'AIC est p = 3.

Les deux approches confirment le même résultat

▼ Confrontation avec les résultats d'ACF et PACF



Les graphes ACF et PACF confirment les résultats. En effet, on remarque une chute brutale des coefficients après le 3ème lags, et une non significativité de ces derniers, au vu de leurs présence en dehors de la zone du cône bleu dans le PACF.

▼ Détermination des paramètres

Les paramètres du modèle sont:

```
const      0.546243
L1.CPI     0.582774
L2.CPI     -0.018421
L3.CPI     0.297893
dtype: float64
```

AR Model Results

```
=====
Dep. Variable:          C - P I
Model:                AR(3)  Log Likelihood      -426.870
Method:              cmle   S.D. of innovations      1.884
Date:                Sun, 16 May 2021  AIC      1.315
Time:                23:10:22  BIC      1.395
Sample:              0      HQIC      1.347
=====
```

```
=====
          coef    std err          z      P>|z|      [0.025    0.975]
-----
const          0.5462     0.229     2.383     0.017     0.097     0.995
L1.CPI          0.5828     0.067     8.730     0.000     0.452     0.714
L2.CPI         -0.0184     0.078    -0.236     0.813    -0.171     0.134
L3.CPI          0.2979     0.067     4.471     0.000     0.167     0.428
=====
```


Roots

```
=====
          Real      Imaginary      Modulus      Frequency
-----
AR.1         1.0906      -0.0000j         1.0906      -0.0000
AR.2        -0.5144      -1.6774j         1.7545      -0.2974
AR.3        -0.5144      +1.6774j         1.7545       0.2974
=====
```

On a donc :

$$inf_t = 0.546243 + 0.582774 * inf_{t-1} - 0.018421 * inf_{t-2} + 0.297893 * inf_{t-3} + \epsilon_t$$

- ▼ Etude du modèle de Philips
- ▼ Visualisation du rapport entre le chômage et l'inflation



Les paramètres du modèle sont:

- Coefficient directeur : [0.003977]
- Intercept : 6.070818917241152

▼ Etude du modèle linéaire

```

=====
                        OLS Regression Results
=====
Dep. Variable:          Unemp      R-squared:                0.000
Model:                  OLS        Adj. R-squared:           -0.005
Method:                 Least Squares    F-statistic:           0.01214
Date:                  Sun, 16 May 2021    Prob (F-statistic):     0.912
Time:                  23:10:22      Log-Likelihood:        -400.28
No. Observations:      211          AIC:                   804.6
Df Residuals:          209          BIC:                   811.3
Df Model:               1
Covariance Type:       nonrobust
=====
                        coef      std err          t      P>|t|      [0.025      0.975]
-----
const                6.0708      0.181      33.576      0.000      5.714      6.427
x1                   0.0040      0.036       0.110      0.912     -0.067      0.075
=====
Omnibus:              13.872    Durbin-Watson:           0.044
Prob(Omnibus):         0.001    Jarque-Bera (JB):        15.356
Skew:                  0.660    Prob(JB):                0.000463
Kurtosis:              2.937    Cond. No.                8.32
=====


```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Nous avons une faible liaison linéaire positive entre Unemp et Inf, ce qui est étrange compte tenu des travaux d'Alban William Phillips qui lui la supposaient négative. En effet nous avons un coefficient de régression de 0.004 ce qui implique que plus l'inflation augmente, plus le taux de chômage sera important. Cependant nous pouvons remarquer que le coefficient directeur est non significatif au vu de la p-value. Donc le modèle semble ne pas être pertinent, ce qui confirme les résultats obtenus au niveau de la visualisation de la relation (un nuage de point, sans réelle courbe décelable).

▼ Inspection des résidus



La courbe des résidus semble refléter une non stationnarité et une autocorrélation. Nous pouvons le remarquer du fait que les valeurs positives resp(négatives) succèdent aux valeurs positives resp(négatives), avec une certaine cyclicité.

Application du Test de Durbin Watson d'autocorrélation des erreurs

Le test de Durbin–Watson permet de détecter la présence d'autocorrélation de lag 1 dans les résidus d'une régression linéaire. Il correspond à un test d'autocorrélation des termes d'erreurs d'ordre 1.

$$u_t = \rho * u_{t-1} + \epsilon_t$$

avec

$$\epsilon_t \sim N(0, \sigma_{\epsilon}^2)$$

Il s'agira de tester les hypothèses suivantes

- $H_0 : \rho = 0$
- $H_1 : \rho \neq 0$

La statistique de Durbin Watson (DW) est définie telle que:

$$DW = \frac{\sum_{t=2}^n (\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=1}^n \hat{u}_t^2}$$

La statistique de Durbin-Watson sera toujours comprise entre 0 et 4. Une valeur de 2 montre qu'il n'y a pas d'autocorrélation dans l'échantillon. Une valeur entre 0 et 2 montre qu'il y a une autocorrélation positive, et une valeur entre 2 et 4 montre qu'il y a une autocorrélation négative.

Pour plus d'informations:

- https://en.wikipedia.org/wiki/Durbin%E2%80%93Watson_statistic
- <https://www.investopedia.com/terms/d/durbin-watson-statistic.asp>
- https://www.perso.gate.cnrs.fr/fournier/Notes_de_cours/Econometrie/2_Autocorrelation.pdf

Valeur de la statistique de Durbin Watson : 0.044194128074711944

Selon le test de Durbin Watson nous avons une forte autocorrélation positive des erreurs. (Les résultats sont également présents sur le modèle linéaire qui précède).

▼ Correction de l'autocorrélation des erreurs

On considère le modèle simple:

- $y_{t-1} = \beta_0 + \beta_1 x_{t-1} + u_{t-1}$
- $y_t = \beta_0 + \beta_1 x_t + u_t$

On réalise une différence des deux équations :

- $y_t - \rho y_{t-1} = \beta_0(1 - \rho) + \beta_1(x_t - \rho x_{t-1}) + \epsilon_t, t > 1$

On réalise une régression sans autocorrélation:

- $\tilde{y}_t = (1 - \rho)\beta_0 + \beta_1 \tilde{x}_t + \epsilon_t, t > 1$

où

- $\tilde{x}_t = x_t - \rho x_{t-1}$
- $\tilde{y}_t = y_t - \rho y_{t-1}$
- ρ correspond au coefficient de corrélation entre les résidus

- **Détermination de rho**

Coefficient du modèle OLS sans constante.

```

=====
                        OLS Regression Results
=====
Dep. Variable:          y      R-squared (uncentered):          0.956
Model:                  OLS    Adj. R-squared (uncentered):      0.956
Method:                 Least Squares    F-statistic:          4557.
Date:                  Sun, 16 May 2021    Prob (F-statistic):    6.88e-144
Time:                  23:10:22    Log-Likelihood:        -70.409
No. Observations:      210    AIC:                   142.8
Df Residuals:          209    BIC:                   146.2
Df Model:              1
Covariance Type:       nonrobust
=====
                        coef      std err          t      P>|t|      [0.025      0.975]
-----
x1                0.9799      0.015      67.507      0.000      0.951      1.009
=====
Omnibus:              78.916    Durbin-Watson:          0.666
Prob(Omnibus):         0.000    Jarque-Bera (JB):        244.932
Skew:                  1.583    Prob(JB):                6.51e-54
Kurtosis:              7.239    Cond. No.                1.00
=====

```

Notes:

[1] R^2 is computed without centering (uncentered) since the model does not contain a constant.

[2] Standard Errors assume that the covariance matrix of the errors is correctly specified.

La valeur du coefficient rho est de: 0.97992

```

=====
                        OLS Regression Results
=====
Dep. Variable:          Unemp    R-squared (uncentered):      0.017
Model:                  OLS      Adj. R-squared (uncentered):    0.013
Method:                 Least Squares    F-statistic:                3.661
Date:                   Sun, 16 May 2021    Prob (F-statistic):         0.0571
Time:                   23:10:22    Log-Likelihood:             -83.092
No. Observations:       210    AIC:                        168.2
Df Residuals:           209    BIC:                        171.5
Df Model:                1
Covariance Type:        nonrobust
=====
               coef      std err          t      P>|t|      [0.025      0.975]
-----
CPI            -0.0225      0.012     -1.913      0.057     -0.046      0.001
=====
Omnibus:                 81.676    Durbin-Watson:              0.613
Prob(Omnibus):            0.000    Jarque-Bera (JB):            279.168
Skew:                     1.598    Prob(JB):                    2.40e-61
Kurtosis:                 7.658    Cond. No.                     1.00
=====

```

Notes:

- [1] R² is computed without centering (uncentered) since the model does not contain a constant.
- [2] Standard Errors assume that the covariance matrix of the errors is correctly specified.

▼ Test de la stabilité de la relation entre le chômage et l'inflation


Afin d'étudier la stabilité de la relation entre chômage et inflation nous utiliserons le test de Chow.

La date du split est: 1986-04-01 00:00:00

- Statistique de Fisher: 1.9419731635492827
- P-value 0.14602473569409172
- N = 211
- K = 4

La p-value est de 0.15, et la statistique de Fisher à 0.14. Donc l'hypothèse H0 ne peut pas être rejetée avec un risque à 5%. Il n'y a donc pas de changement structurel dans à la date de séparation.

▼ Détection de point de rupture



- La date de rupture est 1970-10-01 00:00:00
- La statistique de Fisher est de 27.68181714348758
- La p-value associée est 2.2202618929086777e-11

La valeur la plus élevée de la statistique de Fisher est associée à une p-value très faible (quasi nulle). Donc on rejette l'hypothèse qu'il n'y a pas de changement de structure. Et on détermine le point de rupture principal en 1970.

La valeur la plus élevée de la statistique de Fisher est associée à une p-value très faible (quasi nulle). Donc on rejette l'hypothèse qu'il n'y a pas de changement de structure. Et on détermine le point de rupture principal en 1970.

▼ Test de Granger de non causalité

On considère les délais d'ordre 1, 2, 3 et 4. On étudiera donc le modèle suivant:

$$unemp_t = \beta_1 inf_{t-1} + \beta_2 inf_{t-2} + \beta_3 inf_{t-3} + \beta_4 inf_{t-4} + \delta_1 unemp_{t-1} + \delta_2 unemp_{t-2} + \delta_3 unemp_{t-3} + \delta_4 inf_{t-4} + coontante$$

Afin d'effectuer le test de Granger, nous devons tester l'hypothèse suivante:

- $H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$
- H_1 : correspond donc au cas où un de ces coefficients β est non nul.

Paramètres utilisés:

- N = 207
- P = 9
- q: 4
- La statistique de Fisher est de 3.7966991982053155
- La p-value associée est 0.005351957807937182

Au vu de la statistique de Fisher obtenue, et le fait que la p_value soit inférieure à 0.05 donc on rejette l'hypothèse nulle. Les valeurs de des différents lags étudiés de l'inflation ont un impact sur le chômage.

▼ Représentation graphique des délais distribués


```

                                OLS Regression Results
=====
Dep. Variable:                  Unemp    R-squared:                  0.104
Model:                          OLS      Adj. R-squared:             0.081
Method:                        Least Squares  F-statistic:                4.650
Date:                          Sun, 16 May 2021  Prob (F-statistic):       0.000487
Time:                          23:10:23    Log-Likelihood:            -383.05
No. Observations:              207        AIC:                      778.1
Df Residuals:                  201        BIC:                      798.1
Df Model:                      5
Covariance Type:               nonrobust
=====
                                coef    std err          t      P>|t|      [0.025    0.975]
-----
inflation          -0.0984      0.058      -1.703      0.090      -0.212     0.016
inflation_1        -0.0603      0.067      -0.896      0.371      -0.193     0.072
inflation_2         0.0061      0.064       0.094      0.925      -0.121     0.133
inflation_3         0.0552      0.067       0.825      0.411      -0.077     0.187
inflation_4         0.1849      0.057       3.218      0.002       0.072     0.298
constante          5.7414      0.195      29.504      0.000       5.358     6.125
=====
Omnibus:                  35.345    Durbin-Watson:              0.106
Prob(Omnibus):            0.000    Jarque-Bera (JB):           51.968
Skew:                    0.984    Prob(JB):                   5.19e-12
Kurtosis:                4.466    Cond. No.                   19.4
=====

```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.



On peut remarquer que les valeurs sont croissantes au fur et à mesure de l'ajout de lags.

▼ Impact à long terme de l'inflation sur le chômage

OLS Regression Results

```

=====
Dep. Variable:          Unemp      R-squared:                0.363
Model:                  OLS        Adj. R-squared:           0.318
Method:                 Least Squares    F-statistic:             8.110
Date:                  Sun, 16 May 2021    Prob (F-statistic):      8.79e-13
Time:                  23:10:23      Log-Likelihood:          -337.72
No. Observations:      199          AIC:                    703.4
Df Residuals:          185          BIC:                    749.5
Df Model:              13
Covariance Type:       nonrobust
=====

```

| | coef | std err | t | P> t | [0.025 | 0.975] |
|--------------|---------|---------|--------|-------|--------|--------|
| inflation | -0.1171 | 0.052 | -2.256 | 0.025 | -0.220 | -0.015 |
| inflation_1 | -0.0444 | 0.060 | -0.735 | 0.464 | -0.164 | 0.075 |
| inflation_2 | -0.0589 | 0.060 | -0.974 | 0.331 | -0.178 | 0.060 |
| inflation_3 | 0.0225 | 0.063 | 0.356 | 0.722 | -0.102 | 0.147 |
| inflation_4 | 0.0170 | 0.063 | 0.270 | 0.788 | -0.107 | 0.141 |
| inflation_5 | 0.0477 | 0.063 | 0.754 | 0.452 | -0.077 | 0.172 |
| inflation_6 | 0.0409 | 0.063 | 0.648 | 0.518 | -0.084 | 0.166 |
| inflation_7 | 0.0543 | 0.063 | 0.858 | 0.392 | -0.070 | 0.179 |
| inflation_8 | 0.0565 | 0.063 | 0.897 | 0.371 | -0.068 | 0.181 |
| inflation_9 | 0.0194 | 0.063 | 0.307 | 0.759 | -0.105 | 0.144 |
| inflation_10 | 0.0543 | 0.060 | 0.900 | 0.370 | -0.065 | 0.173 |
| inflation_11 | 0.0424 | 0.060 | 0.704 | 0.482 | -0.077 | 0.161 |
| inflation_12 | 0.1236 | 0.052 | 2.367 | 0.019 | 0.021 | 0.227 |
| constante | 5.0541 | 0.195 | 25.905 | 0.000 | 4.669 | 5.439 |

```

=====
Omnibus:                54.618      Durbin-Watson:           0.092
Prob(Omnibus):          0.000      Jarque-Bera (JB):        103.504
Skew:                   1.353      Prob(JB):                3.34e-23
Kurtosis:               5.272      Cond. No.                 34.4
=====

```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

